LR LocalRAG

PRIVATE KNOWLEDGE BASE • POC

用你们自己的文档，
验证一套本地 AI 知识库

在不把内部资料交给公有云的前提下，验证文档解析、语义检索和带来源回答是否能真正帮助团队找到资料。

适用场景 财税 / 律所 / 制造 / 内网　**POC 周期** 5-10 个工作日　**验证方式** 10-20 个真实问题

这次 POC 要验证什么

- 你们约定格式的文档能否被正确解析和切块。
- 真实问题能否检索到真正相关的资料片段。
- 回答是否能给出可核验的来源，而不是“看起来像”。
- 在你们现有机器或测试环境上，响应是否可接受。

POC 交付内容

本地环境部署

FastAPI + Qdrant + Ollama，Docker Compose 启动。

文档索引

文档解析、切块、本地向量化和来源展示。

测试问题集

双方确认 10-20 个代表性问题并记录结果。

评估报告

可用性、限制、问题清单和下一步建议。

客户需要提供

- 10-50 份脱敏文档
- 10-20 个真实问题
- 测试机器或环境
- 1 位业务对接人

参考费用：¥3,000-8,000

以范围确认单为准；如后续进入正式部署，POC 费用可抵扣。客户负责硬件、网络和脱敏资料。

数据边界

文档、向量和模型运行在客户自有环境。首次安装需要联网拉取镜像和模型；初始化完成后，运行时不调用公有云 AI API。

技术栈

Ollama　Qdrant　FastAPI

bge-m3　Qwen2.5　Docker

本阶段不包含

- 扫描件 OCR
- 企业 SSO / 多租户权限
- 复杂业务系统集成
- 7×24 生产级运维

下一步：20 分钟需求确认

邮箱：siquhjh@163.com

GitHub：github.com/Pingredsai/local-rag

请附：行业、文档类型与数量、当前检索方式。